

A reforma do seguro-desemprego de 2015 é identificável em séries agregadas?

Uma avaliação por ARIMA causal (C-ARIMA) e os limites da identificação
macroeconômica

Arthur Donato

PPGE — FURG (Mestrado em Economia Aplicada)

4 de Outubro de 2026

Resumo

A Lei nº 13.134/2015 endureceu o acesso ao seguro-desemprego (SD) no Brasil, elevando de 6 para 12 meses o tempo mínimo de vínculo exigido na primeira solicitação. Avaliamos o efeito dessa reforma sobre o número mensal de requerentes do SD (2000–2025, 304 meses) por triangulação de dois métodos de série temporal interrompida (do inglês *interrupted time series*, ITS): o modelo autorregressivo integrado de médias móveis causal (do inglês *causal ARIMA*, C-ARIMA) de Menchetti et al. (2023), com inferência por reamostragem (*bootstrap*), e o modelo estrutural bayesiano de séries temporais (do inglês *Bayesian structural time series*, BSTS), implementado no *CausalImpact*. Em nível, as *estimativas pontuais* dos dois métodos convergem para uma queda de aproximadamente **16%** (≈ 110 mil requerentes/mês) após julho de 2015. Essa convergência, porém, é enganosa em duas frentes. Primeiro, a inferência honesta do C-ARIMA — que propaga a incerteza de previsão ao longo de um horizonte de 56 meses — já **não distingue** esse efeito de zero (intervalo de confiança de 95% $[-232.965; +30.157]$, $p \approx 0,13$), enquanto o intervalo do *CausalImpact* é muito mais estreito. Segundo, e decisivo: ao incluir as demissões do Cadastro Geral de Empregados e Desempregados (CAGED) como covariável de controle, o efeito **desaparece** em ambos os métodos (+2,4% no C-ARIMA, +2,6% no *CausalImpact*; ambos não significativos). A conclusão central é metodológica: o efeito da reforma **não é robustamente identificável com dados agregados nacionais**, porque a Lei coincidiu com a recessão de 2015–16, que moveu simultaneamente o volume de demissões, a composição das separações e a adesão ao benefício. O estudo delimita, assim, a fronteira de identificação do problema e motiva um desenho de descontinuidade de elegibilidade em microdados.

Palavras-chave: seguro-desemprego; Lei 13.134/2015; ARIMA causal; *CausalImpact*; identificação causal.

Classificação JEL: J65, C22, H55.

1 Introdução

O seguro-desemprego (SD) é o principal instrumento de proteção de renda ao trabalhador formal demitido no Brasil. Como todo programa de seguro social, ele carrega um *trade-off* central: provê liquidez e suavização de consumo a quem perde o emprego, mas pode distorcer a intensidade da busca por recolocação (Baily, 1978; Chetty, 2008). Em economias com amplo setor informal, esse cálculo de bem-estar é modificado pela possibilidade de transição para a informalidade (Gerard and Gonzaga, 2021).

Em dezembro de 2014 o Governo Federal editou a Medida Provisória (MP) nº 665, convertida na **Lei nº 13.134, de 16 de junho de 2015** (Brasil, 2015), que endureceu o acesso ao benefício. A mudança mais saliente foi o tempo mínimo de vínculo exigido para a **primeira solicitação**, que subiu de cerca de 6 para **12 meses** nos últimos 18 (a segunda solicitação passou a exigir 9 meses; a terceira em diante permaneceu em 6). O governo projetava economia da ordem de R\$ 6,4 bilhões e cerca de 1,6 milhão de trabalhadores (19%) fora do benefício já em 2015.

Apesar da relevância fiscal e social da reforma, **avaliações causais dedicadas são escassas**. A referência mais próxima é descritiva (Amorim et al., 2024), baseada em tabulações anuais da Base de Gestão do Seguro-Desemprego (BGSD). Este trabalho parte dessa lacuna e pergunta: *qual foi o efeito da Lei 13.134/2015 sobre o fluxo de requerentes do SD?* Mais importante, documenta *se* essa pergunta pode ser respondida com os dados agregados disponíveis.

A contribuição é dupla. Primeiro, oferecemos a primeira avaliação quantitativa da reforma de 2015 com a série mensal completa (2000–2025), aplicando o estimador de ARIMA causal (C-ARIMA) e triangulando-o com o *CausalImpact*. Segundo — e este é o achado central — mostramos que o efeito aparente de -16% em nível é **confundido pela recessão de 2015–16**: ele não resiste nem à inferência honesta de um único método (o intervalo de confiança do C-ARIMA já cobre o zero), nem à inclusão da dinâmica de demissões como controle (quando o efeito desaparece em ambos os métodos). O resultado é, portanto, uma *nota de não-identificação*: delimitamos o que os dados agregados conseguem e o que não conseguem sustentar, e derivamos daí o desenho de microdados necessário para uma identificação limpa.

2 Revisão de literatura

2.1 Teoria: seguro versus incentivo

O arcabouço moderno do SD ótimo origina-se em Baily (1978), que formaliza o *trade-off* entre suavização de consumo e distorção da busca. Chetty (2008) reformula o problema decompondo o efeito do benefício sobre a duração do desemprego em uma parcela de **liquidez** (desejável, corrige mercados de crédito incompletos) e uma parcela de **risco moral** (do inglês *moral hazard*, a distorção de incentivo); estima que cerca de 60% do efeito é liquidez, o que justifica benefícios relativamente generosos. Card et al. (2007) fornecem a evidência de que o dinheiro em mãos (do inglês *cash-on-hand*) afeta a duração da busca, sustentando o canal de liquidez.

2.2 Evidência quase-experimental internacional

A fronteira empírica é quase-experimental. Schmieder and von Wachter (2016) sintetizam duas décadas de estimativas (sobretudo por regressão descontínua na Alemanha) e concluem que os efeitos de nível e duração do benefício são pequenos a modestos, com efeito aproximadamente nulo sobre a qualidade média do emprego; extensões em recessão não elevam a duração de forma duradoura. Nekoei and Weber (2017), por sua vez, encontram que estender o SD pode *melhorar* a qualidade do reemprego (melhor compatibilização trabalhador-firma, o *match*). Os padrões de taxa de saída (*hazard*) e os picos (*spikes*) na exaustão do benefício foram estabelecidos por Katz and Meyer (1990) e Meyer (1990); Lalive (2008) é um modelo clássico de regressão descontínua sobre regras de duração.

2.3 Seguro-desemprego no Brasil

A agenda brasileira foi transformada pelos microdados administrativos ligados — a Relação Anual de Informações Sociais (RAIS), o Cadastro Geral de Empregados e Desempregados (CAGED) e o registro do SD. O tema dominante é a **margem informal**: Gerard and Gonzaga (2021) mostram que o custo de eficiência do SD é *menor* em mercados mais informais; Britto (2022) compara proteção de pagamento único (do inglês *lump-sum*, como o Fundo de Garantia do Tempo de Serviço, FGTS) e contingente (SD), concluindo que o SD induz transição para a informalidade mas ainda assim é preferível; Britto et al. (2022) usam regressão descontínua na elegibilidade e mostram que o SD anula o aumento de criminalidade pós-demissão enquanto o benefício dura. Esse último desenho — **regressão descontínua (RD) na descontinuidade de elegibilidade** — é diretamente transponível para a reforma de 2015. No plano descritivo, Amorim et al. (2024) perfilam o acesso repetido ao SD na BGSD e documentam a redução de beneficiários após 2015; Balbinotto Neto and Zylberstajn (2002) e Gonzaga (2003) fornecem o pano de fundo

histórico (reincidência e rotatividade elevada).

2.4 Métodos de avaliação em séries agregadas

Quando o desenho de microdados não está disponível, a avaliação recorre a séries temporais interrompidas (ITS). O modelo autorregressivo integrado de médias móveis (ARIMA) de intervenção remonta a Box and Tiao (1975); o tutorial de Bernal et al. (2017) sistematiza o uso de ITS em avaliação de políticas; a implementação automática de seleção de ordem está em Hyndman and Khandakar (2008). Menchetti et al. (2023) formalizam esse procedimento no arcabouço de resultados potenciais (o **ARIMA causal**, ou C-ARIMA), com inferência por reamostragem (*bootstrap*) sobre os efeitos pontual, médio e acumulado. O *CausalImpact* (Brodersen et al., 2015) segue a mesma lógica com um modelo estrutural bayesiano de séries temporais (BSTS), acomodando covariáveis de controle. A lacuna que todos esses métodos agregados enfrentam — e que este artigo torna explícita — é o confundidor macroeconômico contemporâneo à intervenção; a saída reconhecida pela literatura brasileira é a RD na elegibilidade (Lee and Lemieux, 2010; Calonico et al., 2014; Britto et al., 2022) e as diferenças em diferenças (do inglês *difference-in-differences*, DiD) com múltiplos períodos (Callaway and Sant’Anna, 2021).

3 Dados

A variável de interesse é o **número mensal de requerentes do seguro-desemprego** (trabalhador formal, Brasil), extraído da *Série Histórica do Seguro-Desemprego* da Base de Gestão do Seguro-Desemprego (BGSD), do Ministério do Trabalho e Emprego (MTE). A cobertura é **mensal, de janeiro de 2000 a abril de 2025** (304 observações), por Unidade da Federação (UF) de demissão e para o agregado nacional. A série é contínua, sem lacunas ou valores ausentes.

A escolha da série mensal é deliberada. O estudo descritivo que motivou o projeto (Amorim et al., 2024) usa apenas o agregado *anual* até 2019, insuficiente para modelagem de série temporal — o que torna a série mensal completa (até 2025) a “necessidade de completar a série”.

Como **controle** para a dinâmica do mercado de trabalho, usamos as admissões e demissões mensais do **CAGED antigo** (Instituto de Pesquisa Econômica Aplicada — IPEADATA/MTE, maio/1999 a dezembro/2019). O controle só se aplica à janela da Lei de 2015 (toda pré-2020, antes da quebra metodológica do Novo CAGED). A correlação pré-intervenção entre demissões e requerentes é de **0,93**, o que torna as demissões um preditor forte do contrafactual.

A Figura 1 apresenta a série de requerentes com as duas intervenções datadas, e a Figura 2 sua decomposição sazonal-tendência por *loess* (do inglês *seasonal-trend decom-*

position using loess, STL).




Figura 1: Requerentes mensais do seguro-desemprego (Brasil, 2000–2025), com as intervenções avaliadas: Lei 13.134/2015 (jul/2015) e choque pandêmico (mar/2020).




Figura 2: Decomposição STL da série de requerentes: tendência de longo prazo, sazonalidade mensal e componente remanescente.

4 Metodologia

Avaliamos duas intervenções: a **Lei 13.134/2015** (jul/2015), esperada como um degrau permanente de queda, e o **choque pandêmico** (mar/2020), esperado como pulso agudo seguido de vale. A estratégia é de **triangulação**: dois métodos ITS independentes, com janelas idênticas, cujas concordâncias e discordâncias são informativas.

4.1 ARIMA causal (C-ARIMA)

O método principal é o ARIMA causal de Menchetti et al. (2023). A ideia, no arcabouço de resultados potenciais, é simples: ajusta-se um modelo ARIMA sazonal **apenas na janela pré-intervenção** e projeta-se a série que teria ocorrido na ausência da intervenção — o resultado potencial de controle $\hat{Y}_t(0)$. O efeito causal em cada mês é a diferença entre o observado e esse contrafactual,

$$\hat{\tau}_t = Y_t - \hat{Y}_t(0), \quad t > T_0,$$

e reportamos o **efeito médio temporal** $\bar{\tau} = \frac{1}{H} \sum_{t>T_0} \hat{\tau}_t$ sobre o horizonte de avaliação de H meses. A ordem do ARIMA é selecionada automaticamente por critério de informação (Hyndman and Khandakar, 2008).

A vantagem do C-ARIMA sobre a ITS-contrafactual "manual" é a **inferência**: em vez de intervalos ingênuos, a incerteza do efeito é obtida por reamostragem (*bootstrap*, 1.000 réplicas) da distribuição preditiva, o que propaga corretamente a incerteza de previsão ao longo de todo o horizonte. Essa distinção é material: a aproximação normal para o efeito *médio* é anticonservadora (subestima o erro-padrão), ao passo que o *bootstrap* revela a verdadeira dispersão — como se verá, decisivo para o diagnóstico de (não-)identificação. O método admite covariáveis de controle (x_t) que entram na projeção do contrafactual; usamos as demissões do CAGED nessa função.

A série de requerentes é não estacionária em nível: o teste aumentado de Dickey-Fuller (do inglês *augmented Dickey-Fuller*, ADF) não rejeita a raiz unitária ($p = 0,27$) e o teste KPSS (Kwiatkowski–Phillips–Schmidt–Shin) rejeita a estacionariedade ($p < 0,01$); os critérios automáticos sugerem uma diferença regular ($d = 1$) e nenhuma sazonal. Para a Lei de 2015 (sem controle) o modelo selecionado foi um ARIMA(3,1,1)(0,0,2)₁₂ (186 meses de pré-período; 56 meses de avaliação, encerrando antes da pandemia).

4.2 CausalImpact (BSTS)

O segundo método é o modelo estrutural bayesiano de séries temporais de Brodersen et al. (2015), com componente de tendência local e sazonalidade mensal. Na especificação **sem controle**, o contrafactual é projetado a partir da própria dinâmica pré-intervenção. Na

especificação **com controle**, incluímos as demissões do CAGED como série preditora, de modo que o contrafactual passa a condicionar na trajetória contemporânea do mercado de trabalho. A comparação entre as duas é o teste decisivo do artigo: se o efeito de -16% é um artefato da recessão, ele deve atenuar-se ao controlar pelas demissões.

4.3 Teste da taxa de habilitação

Como verificação adicional, modelamos a **taxa de habilitação** — a razão requerentes/demissões (e segurados/demissões). O raciocínio: se a Lei operou endurecendo a elegibilidade, essa razão deveria *cair* após 2015, independentemente do volume de demissões. Confrontamos quatro estimativas agregadas (nível sem controle; condicional a demissões; taxa contra contrafactual; médias simples pré→pós) para avaliar a robustez do sinal.

Ressalva do denominador. O denominador utilizado é o *total* de desligamentos; o correto seria restringir à **dispensa sem justa causa**, categoria que efetivamente aciona o SD. Como a recessão eleva a fração de separações involuntárias, parte de qualquer movimento na taxa reflete **composição**, não a Lei. O código de layout do CAGED antigo (código 31) permite construir esse denominador correto, pendente apenas do acesso aos microdados.

5 Resultados

5.1 Efeito bruto: estimativas pontuais convergem, mas a incerteza não

Em nível, as estimativas pontuais dos dois métodos concordam de forma marcante (Tabela 1, linhas "sem controle"). Para a Lei de 2015, o C-ARIMA estima -107.779 requerentes/mês ($-15,6\%$) e o *CausalImpact* estima -115.142 ($-16,4\%$) — a mesma ordem de grandeza. A **inferência**, porém, diverge radicalmente. O intervalo de confiança por *bootstrap* do C-ARIMA é $[-232.965, +30.157]$ **ecobre o zero** ($p \approx 0,13$): uma vez propagada a incerteza de previsão ao longo de 56 meses, o método não consegue rejeitar "efeito nulo". Já o intervalo bayesiano do *CausalImpact* é muito mais estreito ($[-173.436, -59.941]$, $p \approx 0,001$). Essa discordância não é um detalhe técnico: a aparente precisão do -16% depende de quanto cada método admite de incerteza no contrafactual (Figuras 3a–3b).

Tabela 1: Triangulação dos efeitos médios sobre requerentes/mês, por método e especificação.

Intervenção / especificação	Método	Efeito médio	IC 95%	Efeito %
Lei 2015 — sem controle	C-ARIMA	−107.779	[−232.965, +30.157]	−15,6%
Lei 2015 — sem controle	CausalImpact	−115.142	[−173.436, −59.941]	−16,4%
Lei 2015 — com controle	C-ARIMA	+13.631	[−26.404, +56.788]	+2,4%
Lei 2015 — com controle	CausalImpact	+14.267	[−14.611, +42.909]	+2,6%
COVID/2020	C-ARIMA	+41.007	[−37.428, +126.766]	+7,9%
COVID/2020	CausalImpact	+15.406	[−32.595, +65.495]	+3,1%

Fonte: elaboração própria. C-ARIMA: intervalo por *bootstrap* (1.000 réplicas); *CausalImpact*: intervalo de credibilidade bayesiano. Ambos a 95%.






Figura 3: Lei 13.134/2015: efeito estimado sobre os requerentes pelos dois métodos ITS, sem controle de demissões. As estimativas pontuais coincidem; a banda de incerteza do C-ARIMA (*bootstrap*) é substancialmente mais larga.

5.2 Efeito condicional: o −16% desaparece ao controlar demissões

O achado central está nas linhas "com controle" da Tabela 1. Ao incluir as demissões do CAGED como controle, o efeito estimado da Lei **muda de sinal e perde qualquer significância** em ambos os métodos: o C-ARIMA vai de −15,6% para +2,4% ($p \approx 0,50$) e o *CausalImpact* de −16,4% para +2,6% ($p \approx 0,15$); nos dois casos o intervalo atravessa o zero. Em outras palavras, uma vez que o contrafactual "sabe" o que aconteceu com as demissões, a queda de requerentes deixa de ser atribuível à reforma: ela é, em grande medida, a sombra da recessão de 2015–16 sobre o fluxo de separações (Figura 4).



(a) C-ARIMA com controle de demissões.



(b) CausalImpact com controle de demissões.

Figura 4: Lei 13.134/2015 **com** controle das demissões do CAGED. Nos dois métodos o efeito pontual aproxima-se de zero e o intervalo cobre o nulo.

5.3 Taxa de habilitação: especificações divergem em sinal

O teste da taxa de habilitação não resgata a identificação — pelo contrário, expõe sua fragilidade. As quatro abordagens agregadas **divergem**, inclusive em sinal (Tabela 2): o nível sem controle dá -16% ; o condicional a demissões dá ≈ 0 ; a taxa requerentes/demissões contra o contrafactual dá $+10\%$ ($p < 0,01$); e a comparação de médias simples pré→pós dá -2% . A razão requerentes/demissões repica durante a recessão e depois reverte (Figura 5) — um padrão **cíclico**, não um degrau de política. Como alertado, parte do “ $+10\%$ ” é composição (mais dispensas involuntárias, elegíveis ao SD), não a Lei.

Tabela 2: Quatro estimativas agregadas do efeito da Lei 2015 — divergência de sinal.

Abordagem	Efeito estimado da Lei 2015
Requerentes (nível), sem controle	-16%
Requerentes demissões (controle CAGED)	≈ 0 (n.s.)
Taxa requerentes/demissões (vs. contrafactual)	$+10\%$ ($p < 0,01$)
Taxa requerentes/demissões (médias simples pré→pós)	-2%

Fonte: elaboração própria. Denominador = total de desligamentos (ressalva de composição no texto).




Figura 5: Taxa de habilitação (requerentes/demissões). O pico coincide com a recessão de 2015–16 e reverte em seguida — dinâmica cíclica, não um degrau permanente de política.

5.4 COVID/2020: efeito líquido nulo

Para completude, o choque pandêmico tem efeito líquido no primeiro ano estatisticamente indistinguível de zero em ambos os métodos (+7,9% no C-ARIMA, $p \approx 0,31$; +3,1% no *CausalImpact*, $p \approx 0,24$). Isso reflete a compensação entre o surto de demissões (abr–jun/2020) e a supressão posterior de desligamentos pela MP 936 e pelo Benefício Emergencial (BEm) — o pulso agudo de demissões é absorvido pela recuperação subsequente, e o efeito médio anual se cancela.

6 Robustez: o mesmo ”efeito” aparece nas demissões

Se a queda de -16% nos requerentes sem controle fosse realmente a reforma, ela **não** deveria aparecer numa série que a Lei não tocou. A Lei 13.134/2015 alterou a elegibilidade do *trabalhador* (tempo de vínculo para solicitar o benefício), não o comportamento de demissão do *empregador*. As demissões do CAGED funcionam, portanto, como uma **série-placebo**: rodamos sobre elas exatamente os mesmos modelos (C-ARIMA e *CausalImpact*, sem controle), na mesma janela em que medimos o efeito sobre os requerentes.

Para uma comparação direta, reestimamos as duas séries na **janela idêntica** imposta pelo fim do CAGED antigo (pré jan/2000–jun/2015; pós jul/2015–dez/2019). O resultado é inequívoco (Tabela 3): as demissões exibem uma queda **igual ou maior** que a dos requerentes — $-17,9\%$ (C-ARIMA) e $-21,9\%$ (*CausalImpact*), contra $-15,3\%$ e $-16,1\%$ dos requerentes — e com o **mesmo padrão de inferência** (o *bootstrap* do C-ARIMA cobre o zero, $p \approx 0,13$; o intervalo bayesiano é estreito, $p \approx 0,001$). A Figura 6 mostra o contrafactual das demissões: o mesmo mergulho pós-2015 que atribuíamos à ”Lei” se olhássemos só os requerentes.

Tabela 3: Robustez: efeito da "Lei 2015" (sem controle) sobre requerentes vs. demissões, janela idêntica (pós jul/2015–dez/2019).

Série	Método	Efeito médio	IC 95%	Efeito %
Requerentes	C-ARIMA	−105.673	[−237.112, +30.090]	−15,3%
Requerentes	CausalImpact	−113.102	[−169.156, −56.222]	−16,1%
Demissões	C-ARIMA	−273.711	[−620.830, +72.355]	−17,9%
Demissões	CausalImpact	−356.959	[−528.058, −190.316]	−21,9%

Fonte: elaboração própria. Demissões = CAGED antigo (IPEADATA/MTE). C-ARIMA: *bootstrap*; *CausalImpact*: credibilidade bayesiana; ambos a 95%. A Lei não alterou o comportamento de demissão do empregador — logo, o efeito sobre as demissões é um placebo.




Figura 6: Robustez — C-ARIMA sobre as **demissões** do CAGED. A série que a Lei não tocou exhibe o mesmo mergulho pós-jul/2015 que atribuiríamos à reforma olhando apenas os requerentes: evidência de que o "efeito" sem controle é a dinâmica de demissões da recessão.

A conclusão do exercício é direta: o "efeito da Lei" estimado sem controle **não é específico dos requerentes**. Ele reaparece — com magnitude percentual ainda maior — numa série que a reforma não poderia ter afetado. Isso corrobora, por um caminho independente do controle da Seção 5.2, que o sinal agregado capta a recessão de 2015–16, não o aperto de elegibilidade.

7 Discussão: por que o agregado não identifica a Lei

A convergência das estimativas pontuais em -16% é sedutora, mas enganosa. A reforma (jul/2015) coincidiu com a **maior recessão recente** do Brasil, que moveu *simultaneamente* três coisas que se confundem no agregado: (i) o volume de demissões; (ii) a *composição* das separações (mais dispensas involuntárias, elegíveis ao SD); e (iii) a adesão ao benefício (*take-up*). Cada especificação agregada carrega esse confundidor de uma forma

diferente — o que explica a divergência de sinal da Tabela 2. O estudo mostra isso em três camadas convergentes: (i) já a inferência honesta de um único método (o *bootstrap* do C-ARIMA) é incapaz de separar o -16% do zero; (ii) ao condicionar o contrafactual na trajetória das demissões, a reforma não deixa pegada distinguível em nenhum dos dois métodos; e (iii) o mesmo “efeito” reaparece na série-placebo de demissões, que a Lei não poderia ter afetado (Seção 6).

A leitura é consistente com Schmieder and von Wachter (2016), para quem efeitos de regras de SD estimados em janelas recessivas são particularmente difíceis de separar do ciclo. A implicação não é que a Lei não teve efeito, mas que **dados agregados nacionais não conseguem isolá-lo** da macroeconomia contemporânea.

O caminho para a identificação. A solução reconhecida pela literatura brasileira (Britto et al., 2022; Gerard and Gonzaga, 2021) é explorar a **descontinuidade de elegibilidade** que a própria Lei criou. O desenho recomendado compara, em microdados ligados pelo Programa de Integração Social (PIS) — RAIS/CAGED/BGSD — trabalhadores de primeira solicitação com vínculo logo abaixo do novo limiar (faixa $[6, 12)$ meses, que *perdem* elegibilidade) contra trabalhadores com vínculo ≥ 12 meses (sempre elegíveis), usando a terceira solicitação (regra inalterada) como placebo. Um grupo de controle que enfrenta a *mesma* recessão faz a diferenciação (*differencing-out*) do confundidor macroeconômico — precisamente o que o agregado não permite. Esse desenho (regressão descontínua na elegibilidade e/ou diferenças-em-descontinuidades, via Calonico et al., 2014; Lee and Lemieux, 2010; Callaway and Sant’Anna, 2021) permitiria, ademais, estimar desfechos de bem-estar (tempo até reemprego, salário no reemprego, transição para informalidade), e não apenas a contagem de solicitações.

8 Conclusão

Este artigo oferece a primeira avaliação quantitativa da reforma do seguro-desemprego de 2015 sobre o fluxo de requerentes, usando a série mensal completa (2000–2025) e a triangulação do ARIMA causal (C-ARIMA) com o *CausalImpact*. O resultado principal é uma **nota de não-identificação**: o efeito aparente de -16% em nível é um artefato da recessão de 2015–16 — ele não sobrevive nem à inferência honesta por *bootstrap* de um único método, nem ao controle pela dinâmica de demissões, e especificações concorrentes divergem em sinal. O estudo delimita, assim, com rigor, o que os dados agregados conseguem sustentar e o que exige um desenho quase-experimental.

A contribuição é tanto substantiva — documentar que a reforma de 2015 *não* é identificável no agregado — quanto metodológica: um estudo de caso de como a coincidência entre uma reforma e um choque macroeconômico corrói a identificação em ITS, e de como diagnosticá-la por triangulação, inferência honesta e controle. O caminho à frente é o

desenho de microdados na descontinuidade de elegibilidade $6 \rightarrow 12$ meses, apto a separar a Lei da recessão e a medir os desfechos de bem-estar que a literatura de desenho do seguro-desemprego considera centrais.

Referências

- Amorim, B., Sousa, V. E. C. M., and Silva, S. P. (2024). Perfil e padrões de acesso repetido ao seguro-desemprego no Brasil. Texto para Discussão 3059, Instituto de Pesquisa Econômica Aplicada (IPEA), Brasília.
- Baily, M. N. (1978). Some aspects of optimal unemployment insurance. *Journal of Public Economics*, 10(3):379–402.
- Balbinotto Neto, G. and Zylberstajn, H. (2002). Uso repetido do seguro-desemprego no Brasil – 1986-1998: Teoria e evidências. *Economia (ANPEC)*, 3(2):265–302.
- Bernal, J. L., Cummins, S., and Gasparrini, A. (2017). Interrupted time series regression for the evaluation of public health interventions: A tutorial. *International Journal of Epidemiology*, 46(1):348–355.
- Box, G. E. P. and Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association*, 70(349):70–79.
- Brasil (2015). Lei nº 13.134, de 16 de junho de 2015. Altera a Lei n. 7.998/1990 (Programa do Seguro-Desemprego e Abono Salarial). Conversão da MP 665/2014.
- Britto, D. G. C. (2022). The employment effects of lump-sum and contingent job insurance policies: Evidence from Brazil. *The Review of Economics and Statistics*, 104(3):465–482.
- Britto, D. G. C., Pinotti, P., and Sampaio, B. (2022). The effect of job loss and unemployment insurance on crime in Brazil. *Econometrica*, 90(4):1393–1423.
- Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., and Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *The Annals of Applied Statistics*, 9(1):247–274.
- Callaway, B. and Sant’Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2):200–230.
- Calonico, S., Cattaneo, M. D., and Titiunik, R. (2014). Robust nonparametric confidence intervals for regression-discontinuity designs. *Econometrica*, 82(6):2295–2326.

- Card, D., Chetty, R., and Weber, A. (2007). Cash-on-hand and competing models of intertemporal behavior: New evidence from the labor market. *The Quarterly Journal of Economics*, 122(4):1511–1560.
- Chetty, R. (2008). Moral hazard versus liquidity and optimal unemployment insurance. *Journal of Political Economy*, 116(2):173–234.
- Gerard, F. and Gonzaga, G. (2021). Informal labor and the efficiency cost of social programs: Evidence from unemployment insurance in Brazil. *American Economic Journal: Economic Policy*, 13(3):167–206.
- Gonzaga, G. (2003). Labor turnover and labor legislation in Brazil. *Economía (LACEA)*, 4(1):165–207.
- Hyndman, R. J. and Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 27(3):1–22.
- Katz, L. F. and Meyer, B. D. (1990). The impact of the potential duration of unemployment benefits on the duration of unemployment. *Journal of Public Economics*, 41(1):45–72.
- Lalive, R. (2008). How do extended benefits affect unemployment duration? a regression discontinuity approach. *Journal of Econometrics*, 142(2):785–806.
- Lee, D. S. and Lemieux, T. (2010). Regression discontinuity designs in economics. *Journal of Economic Literature*, 48(2):281–355.
- Menchetti, F., Cipollini, F., and Mealli, F. (2023). Combining counterfactual outcomes and ARIMA models for policy evaluation. *The Econometrics Journal*, 26(1):1–24.
- Meyer, B. D. (1990). Unemployment insurance and unemployment spells. *Econometrica*, 58(4):757–782.
- Nekoei, A. and Weber, A. (2017). Does extending unemployment benefits improve job quality? *American Economic Review*, 107(2):527–561.
- Schmieder, J. F. and von Wachter, T. (2016). The effects of unemployment insurance benefits: New evidence and interpretation. *Annual Review of Economics*, 8:547–581.