

A reforma do seguro-desemprego de 2015 é identificável em séries agregadas?

Uma avaliação por séries temporais interrompidas e os limites da identificação macroeconômica

Arthur Donato

PPGE — FURG (Mestrado em Economia Aplicada)

3 de Outubro de 2026

Resumo

A Lei nº 13.134/2015 endureceu o acesso ao seguro-desemprego (SD) no Brasil, elevando de 6 para 12 meses o tempo mínimo de vínculo exigido na primeira solicitação. Avaliamos o efeito dessa reforma sobre o número mensal de requerentes do SD (2000–2025, 304 meses) por triangulação de dois métodos de série temporal interrompida (ITS): ARIMA de intervenção com contrafactual e o modelo estrutural bayesiano *CausalImpact* (BSTS). Em nível, os dois métodos convergem em uma queda de aproximadamente **16%** (≈ 114 mil requerentes/mês) após julho de 2015. Esse resultado, porém, **não sobrevive** à inclusão das demissões do CAGED como covariável de controle: o efeito desaparece ($+2,6\%$, $p \approx 0,15$) e o intervalo de credibilidade encolhe pela metade. Especificações alternativas sobre a taxa de habilitação (requerentes/demissões) divergem em sinal. A conclusão central é metodológica: o efeito da reforma **não é robustamente identificável com dados agregados nacionais**, porque a Lei coincidiu com a recessão de 2015–16, que moveu simultaneamente o volume de demissões, a composição das separações e o *take-up*. O estudo delimita, assim, a fronteira de identificação do problema e motiva um desenho de descontinuidade de elegibilidade (RD/DiD) em microdados.

Palavras-chave: seguro-desemprego; Lei 13.134/2015; séries temporais interrompidas; *CausalImpact*; identificação causal.

Classificação JEL: J65, C22, H55.

1 Introdução

O seguro-desemprego (SD) é o principal instrumento de proteção de renda ao trabalhador formal demitido no Brasil. Como todo programa de seguro social, ele carrega um *trade-off*

central: provê liquidez e suavização de consumo a quem perde o emprego, mas pode distorcer a intensidade da busca por recolocação (Baily, 1978; Chetty, 2008). Em economias com amplo setor informal, esse cálculo de bem-estar é modificado pela possibilidade de transição para a informalidade (Gerard and Gonzaga, 2021).

Em dezembro de 2014 o Governo Federal editou a MP 665, convertida na **Lei nº 13.134, de 16 de junho de 2015** (Brasil, 2015), que endureceu o acesso ao benefício. A mudança mais saliente foi o tempo mínimo de vínculo exigido para a **primeira solicitação**, que subiu de cerca de 6 para **12 meses** nos últimos 18 (a segunda solicitação passou a exigir 9 meses; a terceira em diante permaneceu em 6). O governo projetava economia da ordem de R\$ 6,4 bilhões e cerca de 1,6 milhão de trabalhadores (19%) fora do benefício já em 2015.

Apesar da relevância fiscal e social da reforma, **avaliações causais dedicadas são escassas**. A referência mais próxima é descritiva (Amorim et al., 2024), baseada em tabulações anuais da Base de Gestão do Seguro-Desemprego (BGSD). Este trabalho parte dessa lacuna e pergunta: *qual foi o efeito da Lei 13.134/2015 sobre o fluxo de requerentes do SD?* Mais importante, documenta *se* essa pergunta pode ser respondida com os dados agregados disponíveis.

A contribuição é dupla. Primeiro, oferecemos a primeira avaliação quantitativa da reforma de 2015 com a série mensal completa (2000–2025) por triangulação de dois métodos de série temporal interrompida. Segundo — e este é o achado central — mostramos que o efeito aparente de -16% em nível é **confundido pela recessão de 2015–16**: ao controlar pela dinâmica de demissões, o efeito desaparece, e especificações concorrentes divergem em sinal. O resultado é, portanto, uma *nota de não-identificação*: delimitamos o que os dados agregados conseguem e o que não conseguem sustentar, e derivamos daí o desenho de microdados necessário para uma identificação limpa.

2 Revisão de literatura

2.1 Teoria: seguro versus incentivo

O arcabouço moderno do SD ótimo origina-se em Baily (1978), que formaliza o *trade-off* entre suavização de consumo e distorção da busca. Chetty (2008) reformula o problema decompondo o efeito do benefício sobre a duração do desemprego em uma parcela de **liquidez** (desejável, corrige mercados de crédito incompletos) e uma parcela de **moral hazard** (distorção de incentivo); estima que cerca de 60% do efeito é liquidez, o que justifica benefícios relativamente generosos. Card et al. (2007) fornecem a evidência de que o *cash-on-hand* afeta a duração da busca, sustentando o canal de liquidez.

2.2 Evidência quase-experimental internacional

A fronteira empírica é quase-experimental. Schmieder and von Wachter (2016) sintetizam duas décadas de estimativas (sobretudo RD na Alemanha) e concluem que os efeitos de nível e duração do benefício são pequenos a modestos, com efeito aproximadamente nulo sobre a qualidade média do emprego; extensões em recessão não elevam a duração de forma duradoura. Nekoei and Weber (2017), por sua vez, encontram que estender o SD pode *melhorar* a qualidade do reemprego (melhor *match*). Os padrões de *hazard* de saída e os *spikes* na exaustão do benefício foram estabelecidos por Katz and Meyer (1990) e Meyer (1990); Lalive (2008) é um template clássico de RD sobre regras de duração.

2.3 Seguro-desemprego no Brasil

A agenda brasileira foi transformada pelos microdados administrativos ligados (RAIS/CAGED/registro do SD). O tema dominante é a **margem informal**: Gerard and Gonzaga (2021) mostram que o custo de eficiência do SD é *menor* em mercados mais informais; Britto (2022) compara proteção *lump-sum* (FGTS/multa) e contingente (SD), concluindo que o SD induz transição para a informalidade mas ainda assim é preferível; Britto et al. (2022) usam RD na elegibilidade e mostram que o SD anula o aumento de criminalidade pós-demissão enquanto o benefício dura. Esse último desenho — **RD na descontinuidade de elegibilidade** — é diretamente transponível para a reforma de 2015. No plano descritivo, Amorim et al. (2024) perfilam o acesso repetido ao SD na BGSD e documentam a redução de beneficiários após 2015; Balbinotto Neto and Zylberstajn (2002) e Gonzaga (2003) fornecem o pano de fundo histórico (reincidência e rotatividade elevada).

2.4 Métodos de avaliação em séries agregadas

Quando o desenho de microdados não está disponível, a avaliação recorre a séries temporais interrompidas (ITS). O modelo ARIMA de intervenção remonta a Box and Tiao (1975); o tutorial de Bernal et al. (2017) sistematiza o uso de ITS em avaliação de políticas; a implementação automática de seleção de ordem está em Hyndman and Khandakar (2008). O *CausalImpact* (Brodersen et al., 2015) generaliza a ITS para um modelo estrutural bayesiano de séries temporais (BSTS) com contrafactual, acomodando covariáveis de controle. A lacuna que todos esses métodos agregados enfrentam — e que este artigo torna explícita — é o confundidor macroeconômico contemporâneo à intervenção; a saída reconhecida pela literatura brasileira é a RD na elegibilidade (Lee and Lemieux, 2010; Calonico et al., 2014; Britto et al., 2022) e o DiD com múltiplos períodos (Callaway and Sant’Anna, 2021).

3 Dados

A variável de interesse é o **número mensal de requerentes do seguro-desemprego** (trabalhador formal, Brasil), extraído da *Série Histórica do Seguro-Desemprego* da Base de Gestão do Seguro-Desemprego (BGSD), MTE/SPPE. A cobertura é **mensal, de janeiro de 2000 a abril de 2025** (304 observações), por UF de demissão e para o agregado nacional. A série é contínua, sem lacunas ou valores ausentes.

A escolha da série mensal é deliberada. O estudo descritivo que motivou o projeto (Amorim et al., 2024) usa apenas o agregado *anual* até 2019, insuficiente para modelagem de série temporal — o que torna a série mensal completa (até 2025) a "necessidade de completar a série".

Como **controle** para a dinâmica do mercado de trabalho na especificação do *CausalImpact*, usamos as admissões e demissões mensais do **CAGED antigo** (séries CAGED12_ADMIS e CAGED12_DESLIG, IPEADATA/MTE, 1999-05 a 2019-12). O controle só se aplica à janela da Lei de 2015 (toda pré-2020, antes da quebra do Novo CAGED). A correlação pré-intervenção entre demissões e requerentes é de **0,93**, o que torna as demissões um preditor forte do contrafactual.

A Figura 1 apresenta a série de requerentes com as duas intervenções datadas, e a Figura 2 sua decomposição STL (tendência, sazonalidade, resíduo).




Figura 1: Requerentes mensais do seguro-desemprego (Brasil, 2000–2025), com as intervenções avaliadas: Lei 13.134/2015 (jul/2015) e choque pandêmico (mar/2020).




Figura 2: Decomposição STL da série de requerentes: tendência de longo prazo, sazonalidade mensal e componente remanescente.

4 Metodologia

Avaliamos duas intervenções: a **Lei 13.134/2015** (jul/2015), esperada como um degrau permanente de queda, e o **choque pandêmico** (mar/2020), esperado como pulso agudo seguido de vale. A estratégia é de **triangulação**: dois métodos ITS independentes, com janelas idênticas, cujas concordâncias e discordâncias são informativas.

4.1 ARIMA de intervenção (contrafactual)

A série de requerentes é não estacionária em nível: o teste ADF não rejeita a raiz unitária ($p = 0,27$) e o KPSS rejeita a estacionariedade ($p < 0,01$); os critérios automáticos sugerem uma diferença regular ($d = 1$) e nenhuma sazonal ($D = 0$). Ajustamos um modelo SARIMA **apenas na janela pré-intervenção** e projetamos o contrafactual para o período pós-intervenção. O efeito é a diferença entre o observado e o contrafactual previsto,

$$\hat{\tau}_t = y_t - \hat{y}_t^{\text{contraf}}, \quad t > T_0,$$

com intervalos derivados da distribuição preditiva. Para a Lei de 2015 o modelo selecionado foi um $\text{ARIMA}(0,1,4)(1,0,0)[12]$ (186 meses de pré-período); para o COVID, um $\text{ARIMA}(3,1,1)(1,0,0)[12]$. Como robustez, estimamos também um modelo Box–Tiao com *dummies* de intervenção (Box and Tiao, 1975); ressalve-se que, sob $d = 1$, o termo de **degrau** é mal identificado, ao passo que o **pulso** (COVID) é estimado com confiança.

4.2 CausalImpact (BSTS)

O segundo método é o modelo estrutural bayesiano de séries temporais de Brodersen et al. (2015), com componente de tendência local e sazonalidade mensal. Na especificação **sem controle**, o contrafactual é projetado a partir da própria dinâmica pré-intervenção. Na especificação **com controle**, incluímos as demissões do CAGED como série preditora, de modo que o contrafactual passa a condicionar na trajetória contemporânea do mercado de trabalho. A comparação entre as duas é o teste decisivo do artigo: se o efeito de -16% é um artefato da recessão, ele deve atenuar-se ao controlar pelas demissões.

4.3 Teste da taxa de habilitação

Como verificação adicional, modelamos a **taxa de habilitação** — a razão requerentes/demissões (e segurados/demissões). O raciocínio: se a Lei operou endurecendo a elegibilidade, essa razão deveria *cair* após 2015, independentemente do volume de demissões. Confrontamos quatro estimativas agregadas (nível sem controle; condicional a demissões; taxa contra contrafactual; médias simples pré→pós) para avaliar a robustez do sinal.

Ressalva do denominador. O denominador utilizado é o *total* de desligamentos; o correto seria restringir à **dispensa sem justa causa**, categoria que efetivamente aciona o SD. Como a recessão eleva a fração de separações involuntárias, parte de qualquer movimento na taxa reflete **composição**, não a Lei. O código de layout do CAGED antigo (código 31) permite construir esse denominador correto, pendente apenas do acesso aos microdados.

5 Resultados


5.1 Efeito bruto: os dois métodos convergem em -16%

Em nível, ARIMA-ITS e CausalImpact concordam de forma marcante (Tabela 1). Para a Lei de 2015, o ARIMA-ITS estima -113.056 requerentes/mês ($-16,2\%$; IC 95% $[-276.750, +50.638]$) e o CausalImpact estima -115.142 requerentes/mês ($-16,4\%$; IC 95% $[-173.436, -59.941]$, $p \approx 0,001$). As figuras de ajuste constam das Figuras 3a–3b.

Tabela 1: Triangulação dos efeitos médios sobre requerentes/mês.

Intervenção	Método	Efeito médio	IC 95%	Efeito %
Lei 13.134/2015	ARIMA-ITS	-113.056	[-276.750, +50.638]	-16,2%
Lei 13.134/2015	CausalImpact	-115.142	[-173.436, -59.941]	-16,4%
COVID/2020	ARIMA-ITS	+31.241	[-78.972, +141.453]	+5,9%
COVID/2020	CausalImpact	+15.406	[-32.595, +65.495]	+3,1%

Fonte: elaboração própria. IC do CausalImpact = intervalo de credibilidade bayesiano a 95%.



(a) ARIMA-ITS: observado vs. contrafactual.

(b) CausalImpact (sem controle).

Figura 3: Lei 13.134/2015: efeito estimado sobre os requerentes pelos dois métodos ITS, sem controle de demissões.

5.2 Efeito condicional: o -16% desaparece ao controlar demissões

O achado central está na Tabela 2. Ao incluir as demissões do CAGED como controle no CausalImpact, o efeito estimado da Lei **muda de sinal e perde significância**: de $-16,4\%$ ($p \approx 0,001$) para $+2,6\%$ ($p \approx 0,15$), com o intervalo de credibilidade atravessando zero e **encolhendo pela metade** (de ≈ 113.495 para ≈ 57.520 de largura). Em outras palavras, uma vez que o contrafactual "sabe" o que aconteceu com as demissões, a queda de requerentes deixa de ser atribuível à reforma: ela é, em grande medida, a sombra da recessão de 2015–16 sobre o fluxo de separações (Figura 4).

Tabela 2: CausalImpact da Lei 13.134/2015: sem vs. com controle de demissões (CAGED).

Modelo	Efeito médio	Efeito %	p -valor	Largura IC
Sem controle	-115.142	-16,4%	0,001	113.495
Com controle CAGED	+14.267	+2,6%	0,154	57.520

Fonte: elaboração própria. O controle reduz o efeito a zero estatístico e corta a incerteza pela metade.




Figura 4: CausalImpact da Lei 13.134/2015 **com** controle das demissões do CAGED. O efeito pontual aproxima-se de zero e o intervalo de credibilidade cobre o nulo.

5.3 Taxa de habilitação: especificações divergem em sinal

O teste da taxa de habilitação não resgata a identificação — pelo contrário, expõe sua fragilidade. As quatro abordagens agregadas **divergem**, inclusive em sinal (Tabela 3): o nível sem controle dá -16% ; o condicional a demissões dá ≈ 0 ; a taxa requerentes/demissões contra o contrafactual dá $+10\%$ ($p < 0,01$); e a comparação de médias simples pré→pós dá -2% . A razão requerentes/demissões repica durante a recessão e depois reverte (Figura 5) — um padrão **cíclico**, não um degrau de política. Como alertado, parte do “ $+10\%$ ” é composição (mais dispensas involuntárias, elegíveis ao SD), não a Lei.

Tabela 3: Quatro estimativas agregadas do efeito da Lei 2015 — divergência de sinal.

Abordagem	Efeito estimado da Lei 2015
Requerentes (nível), sem controle	−16%
Requerentes demissões (controle CAGED)	≈ 0 (n.s.)
Taxa requerentes/demissões (vs. contrafactual)	+10% ($p < 0,01$)
Taxa requerentes/demissões (médias simples pré→pós)	−2%

Fonte: elaboração própria. Denominador = total de desligamentos (ressalva de composição no texto).




Figura 5: Taxa de habilitação (requerentes/demissões). O pico coincide com a recessão de 2015–16 e reverte em seguida — dinâmica cíclica, não um degrau permanente de política.

5.4 COVID/2020: efeito líquido nulo

Para completude, o choque pandêmico tem efeito líquido no primeiro ano estatisticamente indistinguível de zero em ambos os métodos (+5,9% no ARIMA-ITS, +3,1% no CausalImpact, $p \approx 0,24$). Isso reflete a compensação entre o surto de demissões (abr–jun/2020) e a supressão posterior de desligamentos pela MP 936/BEm — o pulso agudo é bem capturado pelo modelo com *dummies* (coeficiente do pulso $\approx +301.558$, altamente significativo), mas o efeito médio anual se cancela.

6 Discussão: por que o agregado não identifica a Lei

A convergência dos dois métodos em −16% é sedutora, mas enganosa. A reforma (jul/2015) coincidiu com a **maior recessão recente** do Brasil, que moveu *simultaneamente* três coisas que se confundem no agregado: (i) o volume de demissões; (ii) a *composição* das separações (mais dispensas involuntárias, elegíveis ao SD); e (iii) o *take-up* do benefício. Cada especificação agregada carrega esse confundidor de uma forma diferente — o que explica a divergência de sinal da Tabela 3. O teste decisivo (Tabela 2)

mostra que, uma vez condicionado o contrafactual na trajetória das demissões, a reforma não deixa pegada distinguível.

A leitura é consistente com Schmieder and von Wachter (2016), para quem efeitos de regras de SD estimados em janelas recessivas são particularmente difíceis de separar do ciclo. A implicação não é que a Lei não teve efeito, mas que **dados agregados nacionais não conseguem isolá-lo** da macroeconomia contemporânea.

O caminho para a identificação. A solução reconhecida pela literatura brasileira (Britto et al., 2022; Gerard and Gonzaga, 2021) é explorar a **descontinuidade de elegibilidade** que a própria Lei criou. O desenho recomendado compara, em microdados ligados por PIS (RAIS/CAGED/BGSD), trabalhadores de primeira solicitação com vínculo logo abaixo do novo limiar (faixa $[6, 12)$ meses — que *perdem* elegibilidade) contra trabalhadores com vínculo ≥ 12 meses (sempre elegíveis), usando a terceira solicitação (regra inalterada) como placebo. Um grupo de controle que enfrenta a *mesma* recessão faz o *differencing-out* do confundidor macro — precisamente o que o agregado não permite. Esse desenho (RD na elegibilidade e/ou diff-in-discontinuities, via Calonico et al., 2014; Lee and Lemieux, 2010; Callaway and Sant’Anna, 2021) permitiria, ademais, estimar desfechos de bem-estar (tempo até reemprego, salário no reemprego, transição para informalidade), e não apenas a contagem de solicitações.

7 Conclusão

Este artigo oferece a primeira avaliação quantitativa da reforma do seguro-desemprego de 2015 sobre o fluxo de requerentes, usando a série mensal completa (2000–2025) e a triangulação de dois métodos de série temporal interrompida. O resultado principal é uma **nota de não-identificação**: o efeito aparente de -16% em nível é um artefato da recessão de 2015–16 e não sobrevive ao controle pela dinâmica de demissões, com especificações concorrentes divergindo em sinal. O estudo delimita, assim, com rigor, o que os dados agregados conseguem sustentar e o que exige um desenho quase-experimental.

A contribuição é tanto substantiva — documentar que a reforma de 2015 *não* é identificável no agregado — quanto metodológica: um estudo de caso de como a coincidência entre uma reforma e um choque macroeconômico corrói a identificação em ITS, e de como diagnosticá-la por triangulação e controle. O caminho à frente é o desenho de microdados na descontinuidade de elegibilidade $6 \rightarrow 12$ meses, apto a separar a Lei da recessão e a medir os desfechos de bem-estar que a literatura de desenho do SD considera centrais.

Referências

- Amorim, B., Sousa, V. E. C. M., and Silva, S. P. (2024). Perfil e padrões de acesso repetido ao seguro-desemprego no Brasil. Texto para Discussão 3059, Instituto de Pesquisa Econômica Aplicada (IPEA), Brasília.
- Baily, M. N. (1978). Some aspects of optimal unemployment insurance. *Journal of Public Economics*, 10(3):379–402.
- Balbinotto Neto, G. and Zylberstajn, H. (2002). Uso repetido do seguro-desemprego no Brasil – 1986-1998: Teoria e evidências. *Economia (ANPEC)*, 3(2):265–302.
- Bernal, J. L., Cummins, S., and Gasparrini, A. (2017). Interrupted time series regression for the evaluation of public health interventions: A tutorial. *International Journal of Epidemiology*, 46(1):348–355.
- Box, G. E. P. and Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association*, 70(349):70–79.
- Brasil (2015). Lei nº 13.134, de 16 de junho de 2015. Altera a Lei n. 7.998/1990 (Programa do Seguro-Desemprego e Abono Salarial). Conversão da MP 665/2014.
- Britto, D. G. C. (2022). The employment effects of lump-sum and contingent job insurance policies: Evidence from Brazil. *The Review of Economics and Statistics*, 104(3):465–482.
- Britto, D. G. C., Pinotti, P., and Sampaio, B. (2022). The effect of job loss and unemployment insurance on crime in Brazil. *Econometrica*, 90(4):1393–1423.
- Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., and Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *The Annals of Applied Statistics*, 9(1):247–274.
- Callaway, B. and Sant’Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2):200–230.
- Calonico, S., Cattaneo, M. D., and Titiunik, R. (2014). Robust nonparametric confidence intervals for regression-discontinuity designs. *Econometrica*, 82(6):2295–2326.
- Card, D., Chetty, R., and Weber, A. (2007). Cash-on-hand and competing models of intertemporal behavior: New evidence from the labor market. *The Quarterly Journal of Economics*, 122(4):1511–1560.

- Chetty, R. (2008). Moral hazard versus liquidity and optimal unemployment insurance. *Journal of Political Economy*, 116(2):173–234.
- Gerard, F. and Gonzaga, G. (2021). Informal labor and the efficiency cost of social programs: Evidence from unemployment insurance in Brazil. *American Economic Journal: Economic Policy*, 13(3):167–206.
- Gonzaga, G. (2003). Labor turnover and labor legislation in Brazil. *Economía (LACEA)*, 4(1):165–207.
- Hyndman, R. J. and Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 27(3):1–22.
- Katz, L. F. and Meyer, B. D. (1990). The impact of the potential duration of unemployment benefits on the duration of unemployment. *Journal of Public Economics*, 41(1):45–72.
- Lalive, R. (2008). How do extended benefits affect unemployment duration? a regression discontinuity approach. *Journal of Econometrics*, 142(2):785–806.
- Lee, D. S. and Lemieux, T. (2010). Regression discontinuity designs in economics. *Journal of Economic Literature*, 48(2):281–355.
- Meyer, B. D. (1990). Unemployment insurance and unemployment spells. *Econometrica*, 58(4):757–782.
- Nekoei, A. and Weber, A. (2017). Does extending unemployment benefits improve job quality? *American Economic Review*, 107(2):527–561.
- Schmieder, J. F. and von Wachter, T. (2016). The effects of unemployment insurance benefits: New evidence and interpretation. *Annual Review of Economics*, 8:547–581.