

UNIVERSIDADE FEDERAL DO RIO GRANDE – FURG

Instituto de Ciências Econômicas, Administrativas e Contábeis

Programa de Pós-Graduação em Economia Aplicada

Tarefa 9

VAR ou VEC? Especificação, Estimação e Análise Dinâmica
na Cadeia do Diesel — Brasil (2023–2026)

Disciplina: Econometria

Discente: Arthur Pereira Donato

Matrícula: 184210

Professor: Cristiano Aguiar de Oliveira

Rio Grande, 22 de junho de 2026

Índice

1	Parte 1 – Preparação e Análise Exploratória	4
1.1	Item 1 – Carregamento, Truncamento e Estatísticas Descritivas	4
1.2	Item 2 – Séries em Log ao Longo do Tempo	4
1.3	Item 3 – Correlogramas ACF	6
2	Parte 2 – Testes de Raiz Unitária	8
2.1	Item 4 – Teste ADF	8
2.2	Item 5 – Especificação: VAR em Diferenças, VAR em Níveis ou VEC? . . .	9
3	Parte 3 – Seleção da Ordem do Modelo	9
3.1	Item 6 – VARselect	9
3.2	Item 7 – Justificativa da Ordem $p = 2$	10
4	Parte 4 – Teste de Cointegração de Johansen	10
4.1	Item 8 – Estatísticas do Traço e do Máximo Autovalor	10
4.2	Item 9 – Definição da Especificação Final	11
5	Parte 5 – Estimação do Modelo VEC ($r = 1$)	12
5.1	Item 10 – Vetor de Cointegração β	12
5.2	Item 11 – Coeficientes de Ajustamento α	12
5.3	Item 12 – Dinâmica de Curto Prazo (Γ_1)	13
6	Parte 6 – Diagnósticos	14
6.1	Item 13 – Autocorrelação Serial Multivariada	14
6.2	Item 14 – Heterocedasticidade Condicional (ARCH)	15
6.3	Item 15 – Normalidade Multivariada	15
6.4	Item 16 – Estabilidade Estrutural (OLS-CUSUM)	16
7	Parte 7 – Causalidade de Granger	17
7.1	Item 17 – Tabela de Causalidade	17
7.2	Item 18 – Classificação Endogeneidade/Exogeneidade	18
8	Parte 8 – Funções Impulso-Resposta (IRF)	19
8.1	Itens 19–21 – IRF com Ordenamento de Cholesky	19
9	Parte 9 – Decomposição da Variância do Erro de Previsão (FEVD)	23
9.1	Item 22 – Tabelas FEVD	23
9.2	Item 23 – Interpretação da FEVD	25

10 Parte 10 – Síntese e Interpretação Econômica	26
10.1 Item 24 – Justificativa da Especificação VEC	26
10.2 Item 25 – Interpretação Econômica Integrada	26

1 Parte 1 – Preparação e Análise Exploratória

A base utilizada é a série semanal de preços de combustíveis da ANP, com 161 observações entre 02/01/2023 e 26/01/2026. As três variáveis de interesse são o Brent em reais por barril (`brent_brl_media`), o preço do Diesel A S10 na refinaria/produtor (`dieselA_S10_pi`) e o preço do Diesel B S10 na distribuidora (`dieselB_S10_dist`). Todas foram transformadas em logaritmo natural, de modo que diferenças de log aproximam taxas de variação e coeficientes de regressão correspondem a elasticidades.

1.1 Item 1 – Carregamento, Truncamento e Estatísticas Descritivas

```
# Carrega a base ANP e aplica o truncamento em 26/01/2026
dados <- read.csv("dados_diesel.csv", stringsAsFactors = FALSE, sep = ",")
)
dados$data_inicio <- as.Date(dados$data_inicio)
dados <- dados[dados$data_inicio <= as.Date("2026-01-26"), ] # 161 obs.

# Logaritmos naturais das tres series de interesse
dados$l_brent <- log(dados$brent_brl_media) # Brent R$/barril
dados$l_dA <- log(dados$dieselA_S10_pi) # Diesel A S10, produtor
dados$l_dB <- log(dados$dieselB_S10_dist) # Diesel B S10,
distribuidor
```

Listing 1: Carregamento, truncamento e criação das variáveis em log

Tabela 1: Estatísticas Descritivas das Séries em Logaritmo Natural ($T = 161$)

Variável	Média	D.P.	Mín.	Q1	Mediana	Q3	Máx.
ln(Brent)	6,0094	0,0958	5,8071	5,9258	6,0261	6,0762	6,2183
ln(Diesel A)	1,3415	0,0777	1,1132	1,3112	1,3573	1,3730	1,5129
ln(Diesel B)	1,6605	0,0623	1,4694	1,6474	1,6763	1,6893	1,7570

As estatísticas da Tabela 1 revelam que o Diesel B situa-se sistematicamente acima do Diesel A (mediana 1,676 vs. 1,357 em log), diferença que reflete a margem de distribuição e a tributação adicional incorporada ao ponto de venda. A dispersão relativa do Brent (D.P. = 0,096) é maior do que a do Diesel A (0,078) e do Diesel B (0,062), compatível com a suavização que a política de preços e os contratos de distribuição introduzem ao longo da cadeia.

1.2 Item 2 – Séries em Log ao Longo do Tempo

```
png("outputs/fig01_series_log.png", width = 900, height = 720)
par(mfrow = c(3, 1), mar = c(3, 4, 2.5, 1))

plot(dados$data_inicio, dados$l_brent, type = "l", col = "steelblue", lwd
     = 1.5,
      xlab = "Data", ylab = "log(R$/barril)",
      main = "l_brent - Brent em R$/barril (log natural)")
abline(h = mean(dados$l_brent), lty = 2, col = "gray40")
legend("topright", c("Serie", "Media"), lty = c(1,2),
      col = c("steelblue", "gray40"), bty = "n", cex = 0.85)

plot(dados$data_inicio, dados$l_dA, type = "l", col = "darkorange", lwd =
     1.5,
      xlab = "Data", ylab = "log(R$/litro)",
      main = "l_dA - Diesel A S10, Produtor (log natural)")
abline(h = mean(dados$l_dA), lty = 2, col = "gray40")

plot(dados$data_inicio, dados$l_dB, type = "l", col = "darkgreen", lwd =
     1.5,
      xlab = "Data", ylab = "log(R$/litro)",
      main = "l_dB - Diesel B S10, Distribuidor (log natural)")
abline(h = mean(dados$l_dB), lty = 2, col = "gray40")
dev.off()
```

Listing 2: Paine de séries em log ao longo do tempo (fig01)




Figura 1: Séries em logaritmo natural (2023–2026). A linha tracejada indica a média amostral de cada série.

Os três gráficos da Figura 1 sugerem a presença de **tendência estocástica**: nenhuma das séries oscila em torno de um nível fixo; ao contrário, exibem deriva persistente e desvios prolongados em relação à média. O **co-movimento** entre as três séries é visível, em especial a queda simultânea no primeiro semestre de 2023 e a posterior recuperação, indício de que compartilham um componente de longo prazo — motivação para o teste de cointegração.

1.3 Item 3 – Correlogramas ACF

```
# ACF em nível: decaimento lento indica raiz unitária I(1)
png("outputs/fig02_acf_nivel.png", width = 900, height = 720)
par(mfrow = c(3, 1), mar = c(3, 4, 2.5, 1))
acf(dados$l_brent, lag.max = 20, main = "ACF - l_brent (nível)")
acf(dados$l_dA, lag.max = 20, main = "ACF - l_dA (nível)")
acf(dados$l_dB, lag.max = 20, main = "ACF - l_dB (nível)")
dev.off()

# ACF em 1ª diferença: colapso imediato confirma I(1) -> diferença I(0)
png("outputs/fig03_acf_diff.png", width = 900, height = 720)
par(mfrow = c(3, 1), mar = c(3, 4, 2.5, 1))
```

```
acf(diff(dados$l_brent), lag.max = 20, main = "ACF - Dl_brent (1a
diferenca)")
acf(diff(dados$l_dA), lag.max = 20, main = "ACF - Dl_dA (1a diferenca)
")
acf(diff(dados$l_dB), lag.max = 20, main = "ACF - Dl_dB (1a diferenca)
")
dev.off()
```

Listing 3: ACF em nível e em primeira diferença (fig02 e fig03)




Figura 2: ACF em nível (até defasagem 20). Decaimento lento, típico de séries I(1).




Figura 3: ACF em primeira diferença. Colapso imediato ao intervalo de confiança.

A ACF em nível (Figura 2) apresenta autocorrelações próximas de 1 que decaem de forma extremamente lenta — padrão clássico de série integrada de ordem 1. Após a diferenciação (Figura 3), as autocorrelações colapsam imediatamente para dentro do intervalo de confiança de $\pm 1,96/\sqrt{T}$, comportamento consistente com série $I(0)$ (ruído branco). O padrão em dois estágios é **consistente com a hipótese $I(1)$** para as três variáveis.

2 Parte 2 – Testes de Raiz Unitária

2.1 Item 4 – Teste ADF

```
# H0: raiz unitaria. Rejeita se tau < -1,95 (CV 5%, tau_nc, T~160)
adf_teste <- function(serie) {
  res <- ur.df(serie, type = "none", lags = 6, selectlags = "AIC")
  tau <- res@teststat[1]      # estatistica de teste
  res                        # retorna objeto completo
}

# Nivel
```

```

adf_brent <- adf_teste(dados$l_brent)
adf_dA    <- adf_teste(dados$l_dA)
adf_dB    <- adf_teste(dados$l_dB)

# Primeira diferenca
adf_Dbrent <- adf_teste(diff(dados$l_brent))
adf_DdA    <- adf_teste(diff(dados$l_dA))
adf_DdB    <- adf_teste(diff(dados$l_dB))

```

Listing 4: ADF com type="none", lags=6, selectlags="AIC"(pacote urca)

Tabela 2: Resultados dos Testes ADF (type = "none"; CV 5% = -1,95)

Série	Ordem	$\hat{\tau}$	CV 5%	Decisão
ℓ_{brent}	nível	-0,421	-1,95	Raiz unitária
ℓ_{dA}	nível	-0,254	-1,95	Raiz unitária
ℓ_{dB}	nível	0,026	-1,95	Raiz unitária
$\Delta \ell_{brent}$	1ª dif.	-8,923	-1,95	Estacionária
$\Delta \ell_{dA}$	1ª dif.	-5,545	-1,95	Estacionária
$\Delta \ell_{dB}$	1ª dif.	-5,973	-1,95	Estacionária

Em nível, nenhuma das três séries rejeita a hipótese nula de raiz unitária (os valores $|\hat{\tau}|$ ficam bem abaixo de 1,95). Em primeira diferença, todas rejeitam de forma robusta ($|\hat{\tau}| > 5$, muito acima até do valor crítico de 1%: -2,58). **As três séries são $I(1)$, condição necessária para a aplicação do modelo VEC.**

2.2 Item 5 – Especificação: VAR em Diferenças, VAR em Níveis ou VEC?

Como as três séries são $I(1)$, há três especificações possíveis: (i) **VAR em diferenças**: correto se não houver cointegração ($r = 0$), mas descarta a informação de longo prazo; (ii) **VAR em níveis**: geraria regressão espúria para $I(1)$ sem cointegração; (iii) **VEC**: especificação eficiente se $1 \leq r < k$, pois incorpora tanto a dinâmica de curto prazo quanto o mecanismo de correção de erros (ECT). A **condição necessária para o VEC** é que as séries sejam $I(1)$ e que exista ao menos uma combinação linear estacionária entre elas ($r \geq 1$). A decisão entre essas alternativas é determinada pelo teste de Johansen (Parte 4).

3 Parte 3 – Seleção da Ordem do Modelo

3.1 Item 6 – VARselect

```
Y <- cbind(l_brent = dados$l_brent,
           l_dA     = dados$l_dA,
           l_dB     = dados$l_dB)

sel <- VARselect(Y, lag.max = 8, type = "none")
print(round(sel$criteria, 4))
```

Listing 5: VARselect para $p = 1, \dots, 8$ com $\text{type} = \text{"none"}$

Tabela 3: Critérios de Seleção de Defasagens (VARselect, $p = 1$ a 8)

Critério	$p = 1$	$p = 2$	$p = 3$	$p = 4$	$p = 5$	$p = 6$	$p = 7$	$p = 8$
AIC	-23,572	-23,856	-23,835	-23,795	-23,724	-23,680	-23,619	-23,567
HQ	-23,500	-23,712	-23,618	-23,505	-23,362	-23,246	-23,112	-22,988
SC	-23,394	-23,500	-23,300	-23,082	-22,833	-22,611	-22,372	-22,141
FPE		$5,79 \times 10^{-11}$ a $5,87 \times 10^{-11}$ (mínimo em $p = 2$)						

Todos os quatro critérios (AIC, HQ, SC/BIC e FPE) elegem unanimemente $p = 2$.

3.2 Item 7 – Justificativa da Ordem $p = 2$

Com $k = 3$ variáveis e $T = 161$, cada defasagem adicional consome $k^2 = 9$ parâmetros (3 equações $\times$ 3 variáveis), reduzindo os graus de liberdade e aumentando o risco de overfitting. A escolha $p = 2$ é parcimoniosa e captura a autocorrelação relevante de curto prazo, como confirmado pelos critérios: o AIC cai de -23,572 (em $p = 1$) para -23,856 (em $p = 2$) e volta a subir a partir de $p = 3$. No VECM, a ordem de defasagens nas diferenças será $p - 1 = 1$, resultado em um modelo com $1 + 3 \times 1 = 4$ regressores por equação além do ECT — gerenciável dado o tamanho amostral.

4 Parte 4 – Teste de Cointegração de Johansen

4.1 Item 8 – Estatísticas do Traço e do Máximo Autovalor

```
# ecdet="none": sem constante no vetor de cointegracao (consistente com
ADF)
# K=2: correspondente a p=2 no VAR (K-1=1 lag de diferencas no VECM)
# spec="longrun": parametrizacao em forma de longo prazo
jo_trace <- ca.jo(Y, type = "trace", ecdet = "none", K = 2, spec = "
longrun")
jo_eigen <- ca.jo(Y, type = "eigen", ecdet = "none", K = 2, spec = "
longrun")
```

Listing 6: Teste de Johansen com `ca.jo()` — `ecdet="none"`, $K=2$

Tabela 4: Teste de Johansen — Estatísticas e Valores Críticos ($k = 3$, $T = 161$)

H_0	Traço				Máx. Autovalor			
	Estat.	CV10%	CV5%	CV1%	Estat.	CV10%	CV5%	CV1%
$r = 0$	30,943	28,71	31,52	37,22	18,272	18,90	21,07	25,75
$r \leq 1$	12,671	15,66	17,95	23,52	8,471	12,91	14,90	19,19
$r \leq 2$	4,200	6,50	8,18	11,65	4,200	6,50	8,18	11,65

O teste do **traço** para $H_0 : r = 0$ produz estatística 30,943, superior ao CV de 10% (28,71) mas ligeiramente inferior ao CV de 5% (31,52) — margem de apenas **0,58**. O **máximo autovalor** não rejeita $H_0 : r = 0$ nem a 10%. Para $r \leq 1$ e $r \leq 2$, ambos os testes não rejeitam a hipótese nula (estatísticas abaixo dos CV de 10%), sugerindo que, se houver cointegração, **o número de vetores não excede 1**.

4.2 Item 9 – Definição da Especificação Final

Decisão metodológica: adoto $r = 1$ e estimo o VECM.

Três argumentos fundamentam essa escolha:

1. **Evidência estatística a 10%:** o traço rejeita $H_0 : r = 0$ ao nível de significância de 10% ($30,943 > 28,71$). A diferença de apenas 0,58 para o CV de 5% é insuficiente para afirmar que a ausência de cointegração é “definitiva”.
2. **Prior econômico forte:** Brent, Diesel A (produtor) e Diesel B (distribuidor) são preços da *mesma cadeia produtiva* ligados por custos de refino, logística e tributação relativamente estáveis. A teoria da transmissão de preços prediz a existência de um equilíbrio de longo prazo entre eles (lei do preço único setorial).
3. **Risco de misspecificação:** ignorar a cointegração e estimar VAR em diferenças, quando ela existe, descarta o ECT e gera coeficientes de curto prazo inconsistentes (Engle & Granger, 1987). O custo de incluir um ECT supérfluo (se $r = 0$ verdadeiro) é assintoticamente nulo com $T = 161$.
4. **Baixa potência do traço com T moderado:** a literatura sobre cointegração documenta que o teste do traço tem potência reduzida quando $T \approx 150$ –200 e os autovalores associados aos vetores de cointegração são próximos de zero. Subestimar r (erro do tipo II) é assintoticamente mais custoso do que superestimá-lo (erro do tipo I), pois descarta

informação de longo prazo genuína e enfraquece a identificação do mecanismo de correção de erros.

Se $r = 0$ fosse adotado, o VEC seria inviável: sem vetor de cointegração, não existiria equilíbrio de longo prazo para corrigir e o ECT seria uma combinação linear não-estacionária — estimação inconsistente.

5 Parte 5 – Estimação do Modelo VEC ($r = 1$)

5.1 Item 10 – Vetor de Cointegração β

```
# cajorls() estima o VECM por OLS dado o rank r
vec_fit <- cajorls(jo_trace, r = 1)

# $beta: vetor de cointegracao (normalizado na primeira variavel)
print(round(vec_fit$beta, 4))
```

Listing 7: Estimação do VECM com cajorls() e extração de beta

Tabela 5: Vetor de Cointegração Normalizado $\hat{\beta}$ (normalização: $\ell_{\text{brent}} = 1$)

Variável	Coefficiente
ℓ_{brent}	1,0000
ℓ_{dA}	-3,0072
ℓ_{dB}	2,1388

A relação de equilíbrio de longo prazo estimada é:

$$\widehat{ECT}_t = \ell_{\text{brent}}_t - 3,0072 \ell_{dA}_t + 2,1388 \ell_{dB}_t = 0 \quad (1)$$

Em termos econômicos: um aumento de 1% no Brent (em R\$/barril) está associado, no equilíbrio de longo prazo, a um aumento de $1/3,007 \approx 0,33\%$ no Diesel A produtor (mantido o Diesel B constante). O coeficiente positivo de ℓ_{dB} indica que o spread Diesel B – Diesel A (que representa a margem de distribuição) co-varia positivamente com o Brent: quando o petróleo sobe, a margem entre distribuidor e produtor tende a aumentar, possivelmente refletindo custos logísticos e tributação *ad rem* atrelados ao preço do barril.

5.2 Item 11 – Coeficientes de Ajustamento α

```
resumo_vec <- summary(vec_fit$rlm)

# Cada equacao retorna: Estimate, Std. Error, t value, Pr(>|t|) para ect1
# e para os lags de diferencas (Gamma_1)
```

Listing 8: Extração dos coeficientes alpha do VECM**Tabela 6:** Coeficientes de Ajustamento $\hat{\alpha}$ (linha ect1 do VECM)

Equação	$\hat{\alpha}$	E.P.	t	p -valor	Meia-vida
ℓ_brent	-0,0184	0,0253	-0,726	0,469	37,4 sem.
ℓ_dA	0,0536	0,0139	3,850	0,0002***	—
ℓ_dB	0,0299	0,0083	3,608	0,0004***	—

*** $p < 0,001$. Meia-vida: $-\ln(2)/\ln(1+\hat{\alpha})$, válida apenas para $\hat{\alpha} < 0$ (convergência direta ao equilíbrio). Para $\hat{\alpha} > 0$, o ajustamento é indireto via os β negativos no ECT ($\beta_{dA} = -3,007$); a fórmula de meia-vida não se aplica.

Interpretação dos α :

- ℓ_brent : $\hat{\alpha} = -0,018$ (não significativo, $p = 0,469$). O Brent é **fracamente exógeno no longo prazo**: não se ajusta ao ECT. Isso é economicamente esperado — o preço do petróleo é determinado nos mercados internacionais e não reage a desvios nos preços domésticos do diesel. A meia-vida implícita (se o coeficiente fosse significativo) seria de 37,4 semanas.
- ℓ_dA : $\hat{\alpha} = +0,054$ (significativo, $p < 0,001$). O sinal positivo, combinado com o coeficiente $\beta_{dA} = -3,007 < 0$ no ECT, implica que quando o ECT > 0 (Brent acima do equilíbrio), ℓ_dA aumenta, reduzindo o ECT via $\partial ECT / \partial \ell_dA = -3,007 < 0$. O Diesel A **se ajusta ao equilíbrio de longo prazo de forma indireta**: sobe quando o Brent está “alto” e cai quando está “baixo”.
- ℓ_dB : $\hat{\alpha} = +0,030$ (significativo, $p < 0,001$). Analogamente ao Diesel A, o Diesel B responde ao ECT, mas via $\partial ECT / \partial \ell_dB = +2,139 > 0$: um aumento em ℓ_dB amplifica o ECT. O ajustamento líquido do sistema é garantido pelo forte $\hat{\alpha}_{dA}$ que domina a dinâmica.

5.3 Item 12 – Dinâmica de Curto Prazo (Γ_1)

```
# coef() retorna a matriz de coeficientes (regressores x equacoes)
coef_mat <- coef(vec_fit$rlm)
resumo_vec <- summary(vec_fit$rlm) # inclui EP, t e p-valor
```

```
# Imprime os coeficientes de cada equacao individualmente
for (eq in names(resumo_vec))
  print(round(resumo_vec[[eq]]$coefficients, 4))

# Salva a matriz completa em CSV
write.csv(round(as.data.frame(coef_mat), 4),
          "outputs/tab06_coeficientes_vec.csv", quote = FALSE)
```

Listing 9: Coeficientes completos do VECM por equação ($\Gamma_1 + \text{ECT}$)**Tabela 7:** Coeficientes do VECM — Equação Completa por Variável

Regressor	$\Delta\ell_{\text{brent}}$				$\Delta\ell_{dA}$				$\Delta\ell_{dB}$			
	$\hat{\beta}$	EP	t	p	$\hat{\beta}$	EP	t	p	$\hat{\beta}$	EP	t	p
ect1 _{t-1}	-0,018	0,025	-0,73	0,47	0,054	0,014	3,85	< 0,001***	0,030	0,008	3,61	< 0,001***
constante	0,101	0,140	0,72	0,47	-0,297	0,077	-3,86	< 0,001***	-0,166	0,046	-3,61	< 0,001***
$\Delta\ell_{\text{brent}}_{t-1}$	0,015	0,081	0,19	0,85	0,133	0,044	3,00	0,003**	0,098	0,026	3,71	< 0,001***
$\Delta\ell_{dA}_{t-1}$	-0,173	0,187	-0,93	0,35	-0,242	0,103	-2,35	0,020*	-0,040	0,061	-0,66	0,51
$\Delta\ell_{dB}_{t-1}$	0,317	0,288	1,10	0,27	0,689	0,159	4,35	< 0,001***	0,432	0,094	4,58	< 0,001***

*** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$.

Sobre a equação do Diesel B ($\Delta\ell_{dB}$):

- O **Brent defasado** ($\Delta\ell_{\text{brent}}_{t-1}$) tem efeito significativo positivo (coef. = 0,098, $p < 0,001$): variações semanais no Brent transmitem-se ao Diesel B com um lag.
- O **Diesel B defasado** ($\Delta\ell_{dB}_{t-1}$, coef. = 0,432, $p < 0,001$) indica **persistência de curto prazo** relevante: quase 43% da variação da semana anterior é repassada na semana seguinte.
- O Diesel A defasado ($\Delta\ell_{dA}_{t-1}$, coef. = -0,040, $p = 0,51$) **não** apresenta efeito significativo de curto prazo sobre o Diesel B.

6 Parte 6 – Diagnósticos

6.1 Item 13 – Autocorrelação Serial Multivariada

```
var_fit <- vec2var(jo_trace, r = 1) # reconverte VEC -> VAR em niveis

pt_test <- serial.test(var_fit, lags.pt = 12, type = "PT.asymptotic")
bg_test <- serial.test(var_fit, lags.pt = 12, type = "BG")
```

Listing 10: Testes de autocorrelação serial aplicados ao VECM (via vec2var)

Tabela 8: Testes de Autocorrelação Serial dos Resíduos (12 lags)

Teste	Distribuição	Estatística	p -valor	Decisão
Portmanteau (PT.asym.)	$\chi^2(93)$	80,61	0,817	Não rejeita H_0
Breusch-Godfrey (BG)	$\chi^2(45)$	47,92	0,355	Não rejeita H_0

Ambos os testes não rejeitam a hipótese nula de ausência de autocorrelação serial ($p > 0,35$). Os resíduos do VECM estimado são **ruído branco**, indicando que a especificação $p = 2$ captura adequadamente a dinâmica de curto prazo. Autocorrelação residual persiste quando p é subestimado; a ausência de autocorrelação valida a escolha de $p = 2$.

6.2 Item 14 – Heterocedasticidade Condicional (ARCH)

```
arch_test <- arch.test(var_fit, lags.multi = 5)
# H0: sem efeitos ARCH nos resíduos
```

Listing 11: Teste ARCH multivariado (lags = 5)

O teste ARCH multivariado produz $\chi^2(180) = 190,08$ ($p = 0,289$), não rejeitando a hipótese nula de ausência de heterocedasticidade condicional. Esse resultado pode parecer surpreendente para séries de commodities, que tipicamente exibem clusters de volatilidade. Uma possível explicação é que a série semanal suaviza os saltos diários. Mesmo que houvesse ARCH, a validade assintótica dos estimadores ML do VECM seria mantida (o TCL garante consistência), porém os intervalos de confiança das IRF seriam afetados: por isso utilizamos IC *bootstrap* em vez de analíticos.

6.3 Item 15 – Normalidade Multivariada

```
norm_test <- normality.test(var_fit, multivariate.only = FALSE)
```

Listing 12: Teste de Jarque-Bera por equação e multivariado**Tabela 9:** Testes de Jarque-Bera: Normalidade dos Resíduos

Equação	JB	p -valor	Decisão
ℓ_{brent}	6,06	0,048	Rejeita H_0 (marginalmente)
ℓ_{dA}	435,87	$< 0,001$	Rejeita H_0 (forte)
ℓ_{dB}	6138,57	$< 0,001$	Rejeita H_0 (muito forte)
Multivariado	1010,23	$< 0,001$	Rejeita H_0

Os resíduos apresentam forte não-normalidade, especialmente na equação do Diesel B (JB = 6138), provavelmente devido a caudas pesadas causadas por oscilações abruptas de preços

em semanas específicas. Contudo, **a não-normalidade não invalida o VECM**: (i) com $T = 161$, o Teorema Central do Limite garante que os estimadores de máxima verossimilhança são assintoticamente normais, independentemente da distribuição dos erros; (ii) inferência baseada em bootstrap (usada nas IRF) é robusta à violação de normalidade.

6.4 Item 16 – Estabilidade Estrutural (OLS-CUSUM)

Nota técnica: a função `stability()` do pacote `vars` (v.4.4.2) requer um objeto da classe `varest` e não implementa o método para `vec2var`. O teste foi portanto aplicado ao VAR em níveis auxiliar `VAR(Y, p=2, type="const")`, cujas equações de curto prazo são numericamente equivalentes às do VECM — a estabilidade avaliada corresponde à dinâmica de curto prazo do sistema.

```
# stability() exige classe "varest"; vec2var nao e compativel (v. 4.4.2)
var_niveis <- VAR(as.data.frame(Y), p = 2, type = "const")
stab <- stability(var_niveis, type = "OLS-CUSUM")

png("outputs/fig04_cusum.png", width = 900, height = 720)
plot(stab)      # tres paineis: um por equacao do VAR
dev.off()
```

Listing 13: Estabilidade OLS-CUSUM via VAR em níveis auxiliar (fig04)




Figura 4: Gráficos OLS-CUSUM para as três equações do sistema (VAR em níveis auxiliar). As linhas vermelhas são as bandas de confiança a 5%.

Os gráficos CUSUM da Figura 4 mostram que as trajetórias permanecem dentro das bandas de confiança em todas as três equações ao longo do período 2023–2026. **Não há evidência de quebra estrutural:** os parâmetros do modelo são estáveis no período analisado. Vale notar que o período inclui o reajuste de preços da Petrobras em 2023 e a implementação do PNPB/B15 em 2024; aparentemente, esses eventos não geraram mudanças estruturais nos coeficientes de curto prazo do VAR.

7 Parte 7 – Causalidade de Granger

7.1 Item 17 – Tabela de Causalidade

```
# Para cada par (causa, efeito): F-test da restricao que todos os lags de
# "causa" na equacao de "efeito" sao conjuntamente iguais a zero.
granger_par <- function(causa, efeito, var_obj) {
  eq_lm    <- var_obj$varresult[[efeito]]
  y_full   <- fitted(eq_lm) + residuals(eq_lm)
```

```

X      <- model.matrix(eq_lm)
lag_cols <- grep(paste0("^", causa, "\\..1"), colnames(X))
q      <- length(lag_cols)
rss_full <- sum(residuals(eq_lm)^2)
X_r    <- X[, -lag_cols, drop = FALSE]
rss_r   <- sum(lm.fit(X_r, y_full)$residuals^2)
df_res  <- length(y_full) - ncol(X)
F_val   <- ((rss_r - rss_full) / q) / (rss_full / df_res)
pf(F_val, q, df_res, lower.tail = FALSE) # p-valor
}

# Computa as 6 combinacoes nao-diagonais
for (ca in vars_nms)
  for (ef in vars_nms)
    if (ca != ef) granger_par(ca, ef, var_niveis)

```

Listing 14: Granger par-a-par: F-test por equação (base R, Toda-Yamamoto)**Tabela 10:** Causalidade de Granger par-a-par — $F(2, 151)$ e p -valor (H_0 : causa não Granger-causa o efeito indicado na coluna)

Causa ↓	→ ℓ_{brent}		→ ℓ_{dA}		→ ℓ_{dB}	
	F	p	F	p	F	p
ℓ_{brent}	—	—	5,775	0,004**	7,515	0,001***
ℓ_{dA}	0,577	0,563	—	—	4,038	0,020*
ℓ_{dB}	0,827	0,439	14,019	< 0,001***	—	—

*** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$. GL: $F(2, 151)$ — 2 lags do VAR($p = 2$), 151 graus de liberdade residuais por equação. Toda-Yamamoto: VAR em níveis auxiliar com `type="const"`; inferência Wald válida para séries $I(1)$ com cointegração.

7.2 Item 18 – Classificação Endogeneidade/Exogeneidade

Combinando os resultados de $\hat{\alpha}$ (longo prazo) com os testes Granger (curto prazo), classificamos cada variável:

Tabela 11: Classificação das Variáveis por Grau de Endogeneidade (resultados par-a-par)

Variável	$\hat{\alpha}$ (sig.)	Granger-causa (par-a-par)	Classificação
ℓ_{brent}	Não ($p = 0,469$)	→ ℓ_{dA} ($p = 0,004$) e → ℓ_{dB} ($p = 0,001$)	Fracamente exógena LP; lidera CP
ℓ_{dA}	Sim ($p < 0,001$)	→ ℓ_{dB} ($p = 0,020$); ↗ ℓ_{brent} ($p = 0,563$)	Endógena LP; causa CP → distribuidor
ℓ_{dB}	Sim ($p < 0,001$)	→ ℓ_{dA} ($p < 0,001$); ↗ ℓ_{brent} ($p = 0,439$)	Endógena CP e LP; retroage sobre produtor

A hierarquia empírica **Brent** → **Diesel A** → **Diesel B** é **parcialmente confirmada**:

- O Brent Granger-causa tanto o Diesel A ($p = 0,004$) quanto o Diesel B ($p = 0,001$) no curto prazo, mas não se ajusta ao ECT de longo prazo ($\hat{\alpha}$ não significativo), confirmando sua exogeneidade fraca — ele lidera o sistema sem ser afetado pelos preços domésticos.

- O Diesel A ajusta-se ao equilíbrio de LP (significativo via α) e Granger-causa o distribuidor ($p = 0,020$), mas **não** retroage sobre o Brent ($p = 0,563$), como esperado.
- O Diesel B é endógeno em CP e LP e, surpreendentemente, **Granger-causa fortemente o Diesel A** ($F = 14,019, p < 0,001$) — efeito upstream (distribuidor $\rightarrow$ produtor). Esse resultado sugere que o mercado de distribuição antecipa reajustes e transmite pressão de custo para a refinaria/produtor antes mesmo do repasse formal. Importante: o Diesel B **não** Granger-causa o Brent ($p = 0,439$), mostrando que a retroalimentação é restrita ao mercado doméstico.

8 Parte 8 – Funções Impulso-Resposta (IRF)

8.1 Itens 19–21 – IRF com Ordenamento de Cholesky

```
# Ordenamento: l_brent -> l_dA -> l_dB (da mais exogena a mais endogena)
# No VEC, choques tem efeitos PERMANENTES (IRF nao converge a zero)
irf_fit <- irf(var_fit, n.ahead = 20, boot = TRUE, ci = 0.95, runs = 99)
```

Listing 15: IRF com ordenamento de Cholesky e IC bootstrap




Figura 5: Funções impulso-resposta completas (grade 3×3). Linha sólida: resposta pontual; linhas tracejadas: IC bootstrap 95% (99 rep.).

```
# Calcula cada IRF par-a-par com bootstrap 95% (99 replicacoes)
irf_dB_brent <- irf(var_fit, impulse = "l_brent", response = "l_dB",
                    n.ahead = 20, boot = TRUE, ci = 0.95, runs = 99)
irf_dA_brent <- irf(var_fit, impulse = "l_brent", response = "l_dA",
                    n.ahead = 20, boot = TRUE, ci = 0.95, runs = 99)
irf_dB_dA    <- irf(var_fit, impulse = "l_dA",    response = "l_dB",
                    n.ahead = 20, boot = TRUE, ci = 0.95, runs = 99)

h <- 0:20
png("outputs/fig06_irf_especificas.png", width = 900, height = 900)
par(mfrow = c(3, 1), mar = c(3, 4, 2.5, 1))

# Painel 1: l_dB em resposta a choque em l_brent
plot(h, irf_dB_brent$irf$l_brent, type = "l", col = "steelblue", lwd = 2,
     ylim = range(c(irf_dB_brent$Lower$l_brent, irf_dB_brent$Upper$l_brent)),
     xlab = "Horizonte (semanas)", ylab = "Resposta",
```

```

    main = "Resposta de l_dB a choque unitario em l_brent")
lines(h, irf_dB_brent$Upper$l_brent, lty = 2, col = "gray50")
lines(h, irf_dB_brent$Lower$l_brent, lty = 2, col = "gray50")
abline(h = 0)

# Painel 2: l_dA em resposta a choque em l_brent
plot(h, irf_dA_brent$irf$l_brent, type = "l", col = "darkorange", lwd =
    2,
    ylim = range(c(irf_dA_brent$Lower$l_brent, irf_dA_brent$Upper$l_
        brent))),
    xlab = "Horizonte (semanas)", ylab = "Resposta",
    main = "Resposta de l_dA a choque unitario em l_brent")
lines(h, irf_dA_brent$Upper$l_brent, lty = 2, col = "gray50")
lines(h, irf_dA_brent$Lower$l_brent, lty = 2, col = "gray50")
abline(h = 0)

# Painel 3: l_dB em resposta a choque em l_dA
plot(h, irf_dB_dA$irf$l_dA, type = "l", col = "darkgreen", lwd = 2,
    ylim = range(c(irf_dB_dA$Lower$l_dA, irf_dB_dA$Upper$l_dA)),
    xlab = "Horizonte (semanas)", ylab = "Resposta",
    main = "Resposta de l_dB a choque unitario em l_dA")
lines(h, irf_dB_dA$Upper$l_dA, lty = 2, col = "gray50")
lines(h, irf_dB_dA$Lower$l_dA, lty = 2, col = "gray50")
abline(h = 0)
dev.off()

```

Listing 16: IRF específicas: pares de impulso-resposta selecionados (fig06)




Figura 6: IRF específicas: respostas de ℓ_{dB} e ℓ_{dA} a choque em ℓ_{brent} , e de ℓ_{dB} a choque em ℓ_{dA} .

Resposta de ℓ_{dB} a um choque em ℓ_{brent} : A resposta é gradual e persistente. Na semana imediata ao choque o efeito é mínimo ($\Delta\ell_{dB} \approx 0,0009$), elevando-se rapidamente para 0,010 na semana 4 e alcançando um **platô permanente** em torno de 0,016 ao redor da semana 12–15. Em escala logarítmica, um choque unitário no Brent (desvio padrão de um período) transmite permanentemente cerca de 1,6 p.p. ao Diesel B. Esse efeito permanente é esperado no VEC: as séries $I(1)$ com cointegração propagam choques até o novo nível de equilíbrio.

Resposta de ℓ_{dA} a um choque em ℓ_{brent} : O Diesel A (produtor) responde mais rapidamente e com maior magnitude, atingindo $\approx 0,010$ na semana 3 e 0,022 no horizonte de 20 semanas (vs. 0,016 do Diesel B). O produtor **absorve uma proporção maior** do choque do Brent do que o distribuidor, coerente com o fato de a refinaria ser o elo que compra o petróleo diretamente.

Resposta de ℓ_{dB} a um choque em ℓ_{dA} : A resposta é positiva e persistente. Na primeira semana já há efeito significativo, indicando transmissão quase imediata do produtor para o distribuidor. O efeito se estabiliza em nível positivo, sugerindo **amplificação**: a margem de distribuição incorpora o choque sem amortecê-lo completamente.

Item 21 — Efeitos permanentes no VEC: No VECM, os choques têm efeitos permanentes porque as séries são $I(1)$. Diferentemente do VAR em diferenças — onde as IRF convergem a zero (o choque some da série diferenciada porque ela já não tem “memória” de longo prazo) —, no VEC o choque altera permanentemente o nível das variáveis por meio da cointegração: o sistema se ajusta para um *novo* equilíbrio, não retorna ao original. Isso é economicamente intuitivo: um aumento permanente no preço do petróleo eleva permanentemente o preço do diesel, não apenas temporariamente.

9 Parte 9 – Decomposição da Variância do Erro de Previsão (FEVD)

9.1 Item 22 – Tabelas FEVD

```
# fevd() calcula a decomposicao da variancia para cada variavel do
# sistema
fevd_fit <- fevd(var_fit, n.ahead = 20)

# Grafico empilhado (barchart por horizonte) para as tres equacoes
png("outputs/fig07_fevd.png", width = 900, height = 720)
plot(fevd_fit)
dev.off()

# Tabelas numericas para horizontes selecionados
horizontes <- c(1, 4, 8, 12, 20)

tabela_fevd <- function(var_nome) {
  m      <- fevd_fit[[var_nome]]      # matriz T x k (fracao da
  # variancia)
  m_sel <- round(m[horizontes, ] * 100, 2) # percentuais
  df    <- as.data.frame(m_sel)
  df$Horizonte <- horizontes
  df$Total     <- rowSums(df[, 1:3])
  df[, c("Horizonte", colnames(m), "Total")]
}

tab_fevd_brent <- tabela_fevd("l_brent")
tab_fevd_dA    <- tabela_fevd("l_dA")
tab_fevd_dB    <- tabela_fevd("l_dB")
```

```
write.csv(tab_fevd_brent, "outputs/tab11a_fevd_brent.csv", row.names =
  FALSE)
write.csv(tab_fevd_dA, "outputs/tab11b_fevd_dA.csv", row.names =
  FALSE)
write.csv(tab_fevd_dB, "outputs/tab11c_fevd_dB.csv", row.names =
  FALSE)
```

Listing 17: Decomposição da Variância (FEVD): gráfico e tabelas (fig07)




Figura 7: Decomposição da Variância (FEVD), horizonte 1–20 semanas.

Tabela 12: FEVD: Variável dependente l_{brent} (%)

Horizonte	l_{brent}	l_{dA}	l_{dB}	Total
$h = 1$	100,00	0,00	0,00	100
$h = 4$	99,46	0,05	0,48	100
$h = 8$	99,18	0,27	0,54	100
$h = 12$	98,90	0,56	0,54	100
$h = 20$	98,43	1,05	0,52	100

Tabela 13: FEVD: Variável dependente ℓ_{dA} (%)

Horizonte	ℓ_{brent}	ℓ_{dA}	ℓ_{dB}	Total
$h = 1$	0,70	99,30	0,00	100
$h = 4$	15,29	72,07	12,64	100
$h = 8$	31,82	46,67	21,51	100
$h = 12$	43,05	31,32	25,63	100
$h = 20$	54,40	17,14	28,46	100

Tabela 14: FEVD: Variável dependente ℓ_{dB} (%)

Horizonte	ℓ_{brent}	ℓ_{dA}	ℓ_{dB}	Total
$h = 1$	0,63	34,80	64,57	100
$h = 4$	12,73	21,03	66,24	100
$h = 8$	21,68	10,14	68,18	100
$h = 12$	26,79	5,98	67,22	100
$h = 20$	31,72	4,02	64,26	100

9.2 Item 23 – Interpretação da FEVD

- **O Brent é predominantemente exógeno?** Sim. No horizonte de 20 semanas, 98,4% do erro de previsão de ℓ_{brent} é explicado por choques próprios. O Diesel A contribui com apenas 1,1% e o Diesel B com 0,5%. Isso confirma que o Brent não incorpora informações dos preços domésticos do diesel — ele é o *driver* exógeno do sistema.
- **Fração do erro de previsão do Diesel B explicada pelo Brent e Diesel A (h=20):** Brent = 31,7%, Diesel A = 4,0%, Diesel B próprio = 64,3%. A contribuição do Brent cresce monotonicamente com o horizonte (de 0,6% em $h = 1$ para 31,7% em $h = 20$), confirmando a **hierarquia da cadeia produtiva**. O Diesel A, no entanto, tem contribuição decrescente após $h = 4$, sugerindo que a transmissão do produtor para o distribuidor se concentra no curto prazo.
- **Variável que explica > 20% do erro de outra:** O Brent explica 31,7% do Diesel B a 20 semanas. O Brent também explica 54,4% do Diesel A a 20 semanas — a variável mais impactada. O Diesel A explica 28,5% do Diesel B a 20 semanas em curto prazo ($h=4$) e 34,8% em $h=1$, revelando forte transmissão imediata do produtor para o distribuidor que decai no longo prazo.

10 Parte 10 – Síntese e Interpretação Econômica

10.1 Item 24 – Justificativa da Especificação VEC

A especificação final adotada é o **Modelo de Correção de Erros Vetorial (VECM) com $r = 1$** , estimado com $p = 2$ lags (1 lag de diferenças). Os testes suportaram a escolha em dois níveis: (i) os testes ADF confirmam de forma robusta que as três séries são $I(1)$, condição necessária para qualquer especificação cointegrada; (ii) o teste do traço de Johansen rejeita $H_0 : r = 0$ ao nível de 10% e, combinado com o forte prior econômico de que preços da mesma cadeia produtiva compartilham equilíbrio de longo prazo, justifica $r = 1$. A especificação VEC é preferível às alternativas: o VAR em diferenças ignoraria o ECT e geraria estimadores inconsistentes se $r \geq 1$; o VAR em níveis trataria variáveis $I(1)$ como estacionárias, produzindo regressão espúria. Uma especificação incorreta — p.ex., usar VAR em diferenças quando há cointegração — sub-estima a persistência dos choques, elimina informação de longo prazo dos coeficientes e invalida a interpretação das IRF, que deixariam de mostrar efeitos permanentes.

10.2 Item 25 – Interpretação Econômica Integrada

Os resultados confirmam **(a) a existência de um equilíbrio de longo prazo** entre os três preços, capturado pelo vetor de cointegração $\hat{\beta}' = (1, -3,007, 2,139)$: Brent, Diesel A e Diesel B co-integram, partilhando uma trajetória de longo prazo comum determinada pelos custos de refino, distribuição e tributação. **(b) O Brent é o líder exógeno** do sistema — fracamente exógeno no longo prazo ($\hat{\alpha}_{\text{brent}}$ não significativo) e Granger-causando os preços domésticos no curto prazo. O Diesel A (produtor) é a variável que **lidera o ajustamento ao equilíbrio**: seu $\hat{\alpha}_{dA} = 0,054$ é significativo e, via coeficiente negativo no vetor de cointegração ($\beta_{dA} = -3,007$), corrige desvios de longo prazo. O Diesel B (distribuidor) também é endógeno ($\hat{\alpha}_{dB} = 0,030, p < 0,001$), respondendo tanto ao ECT quanto a choques de curto prazo. **(c) Um choque no Brent demora entre 12 e 15 semanas para se transmitir integralmente ao Diesel B**: a IRF alcança o platô permanente de $\approx 1,6$ p.p. por desvio padrão de choque nesse horizonte. **(d) A estrutura de causalidade empírica é coerente com a cadeia produtiva do diesel**: o petróleo (Brent) determina o custo da matéria-prima, a refinaria (Diesel A) repassa ao distribuidor (Diesel B), que por sua vez exibe a maior persistência e maior contribuição própria na FEVD. O achado adicional de que o Diesel B Granger-causa os demais no curtíssimo prazo sugere que o mercado de distribuição incorpora expectativas de reajuste de forma antecipada — talvez refletindo contratos de distribuição com cláusulas indexadas ao preço do barril que geram pressão de custo antes mesmo do reajuste formal da refinaria.